Examen Final

Alumno: Federico Bonino
Fecha: 24 de Junio de 2024

Ejercicio 1 - Aviación Civil

Consigna

La Administración Nacional de Aviación Civil necesita una serie de informes para elevar al ministerio de transporte acerca de los aterrizajes y despegues en todo el territorio Argentino, como puede ser: cuales aviones son los que más volaron, cuántos pasajeros volaron, ciudades de partidas y aterrizajes entre fechas determinadas, etc.
Usted como data engineer deberá realizar un pipeline con esta información, automatizarlo y realizar los análisis de datos solicitados que permita responder las preguntas de negocio, y hacer sus recomendaciones con respecto al estado actual.

Desarrollo

1. Para realizar la ingesta se utiliza el siguiente script ubicado en `/home/hadoop/scripsts/ingest_aviacion.sh`

```
rm -f /home/hadoop/landing/*.*

wget -O /home/hadoop/landing/2021-informe-ministerio.csv
"https://edvaibucket.blob.core.windows.net/data-engineer-edvai/2021-
informe-ministerio.csv?sp=r&st=2023-11-06T12:59:46Z&se=2025-11-
06T20:59:46Z&sv=2022-11-02&sr=b&sig=%2BSs5xIW3qcwmRh5TTmheIY9ZBa9BJC8XQDcI
%2FPLRe9Y%3D"

wget -O /home/hadoop/landing/2022-informe-ministerio.csv
"https://edvaibucket.blob.core.windows.net/data-engineer-edvai/202206-
informe-ministerio.csv?sp=r&st=2023-11-06T12:52:39Z&se=2025-11-
06T20:52:39Z&sv=2022-11-
02&sr=c&sig=J4Ddi2c7Ep23OhQLPisbYaerlH472iigPwc1%2FkG80EM%3D"

wget -O /home/hadoop/landing/aeropuertos_detalle.csv
"https://edvaibucket.blob.core.windows.net/data-engineer-edvai/aeropuertos
_detalle.csv?sp=r&st=2023-11-06T12:52:39Z&se=2025-11-06T20:52:39Z&sv=2022-
11-02&sr=c&sig=J4Ddi2c7Ep23OhQLPisbYaerlH472iigPwc1%2FkG80EM%3D"

/home/hadoop/hadoop/bin/hdfs dfs -rm /ingest/*.*

/home/hadoop/hadoop/bin/hdfs dfs -put /home/hadoop/landing/*.* /ingest
```

2. Para crear las tablas en el datawarehouse se utiliza el siguiente script ubicado en `/home/hadoop/scripts/create_database.hql`
   El script se corrió manualmente por consola antes de realizar la ingesta mediante `hive -f /home/hadoop/scripts/create_database.hql`

```
-- Create the aviacion_civil database
create database aviacion_civil;
use aviacion_civil;

-- create tables with appropiate schema
create table
    aeropuerto_tabla (
        fecha date,
        horaUTC string,
        clase_de_vuelo string,
        clasificacion_de_vuelo string,
        tipo_de_movimiento string,
        aeropuerto string,
        origen_destino string,
        aerolinea_nombre string,
        aeronave string,
        pasajeros int)
    row format delimited
    fields terminated by ',';

create table
    aeropuerto_detalles_tabla (
        aeropuerto string,
        oac string,
        iata string,
        tipo string,
        denominacion string,
        coordenadas string,
        latitud string,
        longitud string,
        elev float,
        uom_elev string,
        ref string,
        distancia_ref float,
        direccion_ref string,
        condicion string,
        control string,
        region string,
        uso string,
        trafico string,
        sna string,
        concesionado string,
        provincia string)
    row format delimited
    fields terminated by ',';
```

- Para orquestar el proceso de ETL mediante Airflow se utiliza el siguiente script ubicado en `/home/hadoop/airflow/dags/dag_aviacion_civil.py`

```
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.empty import EmptyOperator
from datetime import datetime, timedelta

args = {
    'owner' : 'airflow',
}

with DAG(
    'aviacion_civil_elt',
    default_args=args,
    schedule_interval='@once',
    start_date=datetime(2020, 1, 1),
    dagrun_timeout=timedelta(minutes=60),
    tags=['ingest', 'transform']
)as dag:

    ingest = BashOperator(
        task_id='ingest',
        # Don't drop the space at the end of the command or Jinja will
fail
        bash_command='/usr/bin/sh /home/hadoop/scripts/ingest_aviacion.sh
',
    )

    transform = BashOperator(
        task_id='transform',
        # Don't drop the space at the end of the command or Jinja will
fail
        bash_command='ssh hadoop@172.17.0.2 /home/hadoop/spark/bin/spark-
submit --files /home/hadoop/hive/conf/hive-site.xml
/home/hadoop/scripts/transform_aviacion.py ',
    )

    end_processing = EmptyOperator(
        task_id='end_processing',
    )

    ingest >> transform >> end_processing
```

Esta captura de pantalla muestra la ejecución exitosa del pipeline orquestado por Airflow.
El entorno completo se ejecuta de manera local containerizado en Docker y se accede a las web Uis mediante el navegador (en los puertos correspondientes expuestos) y a los CLI desde la consola con `docker exec -it edvai_hadoop bash`

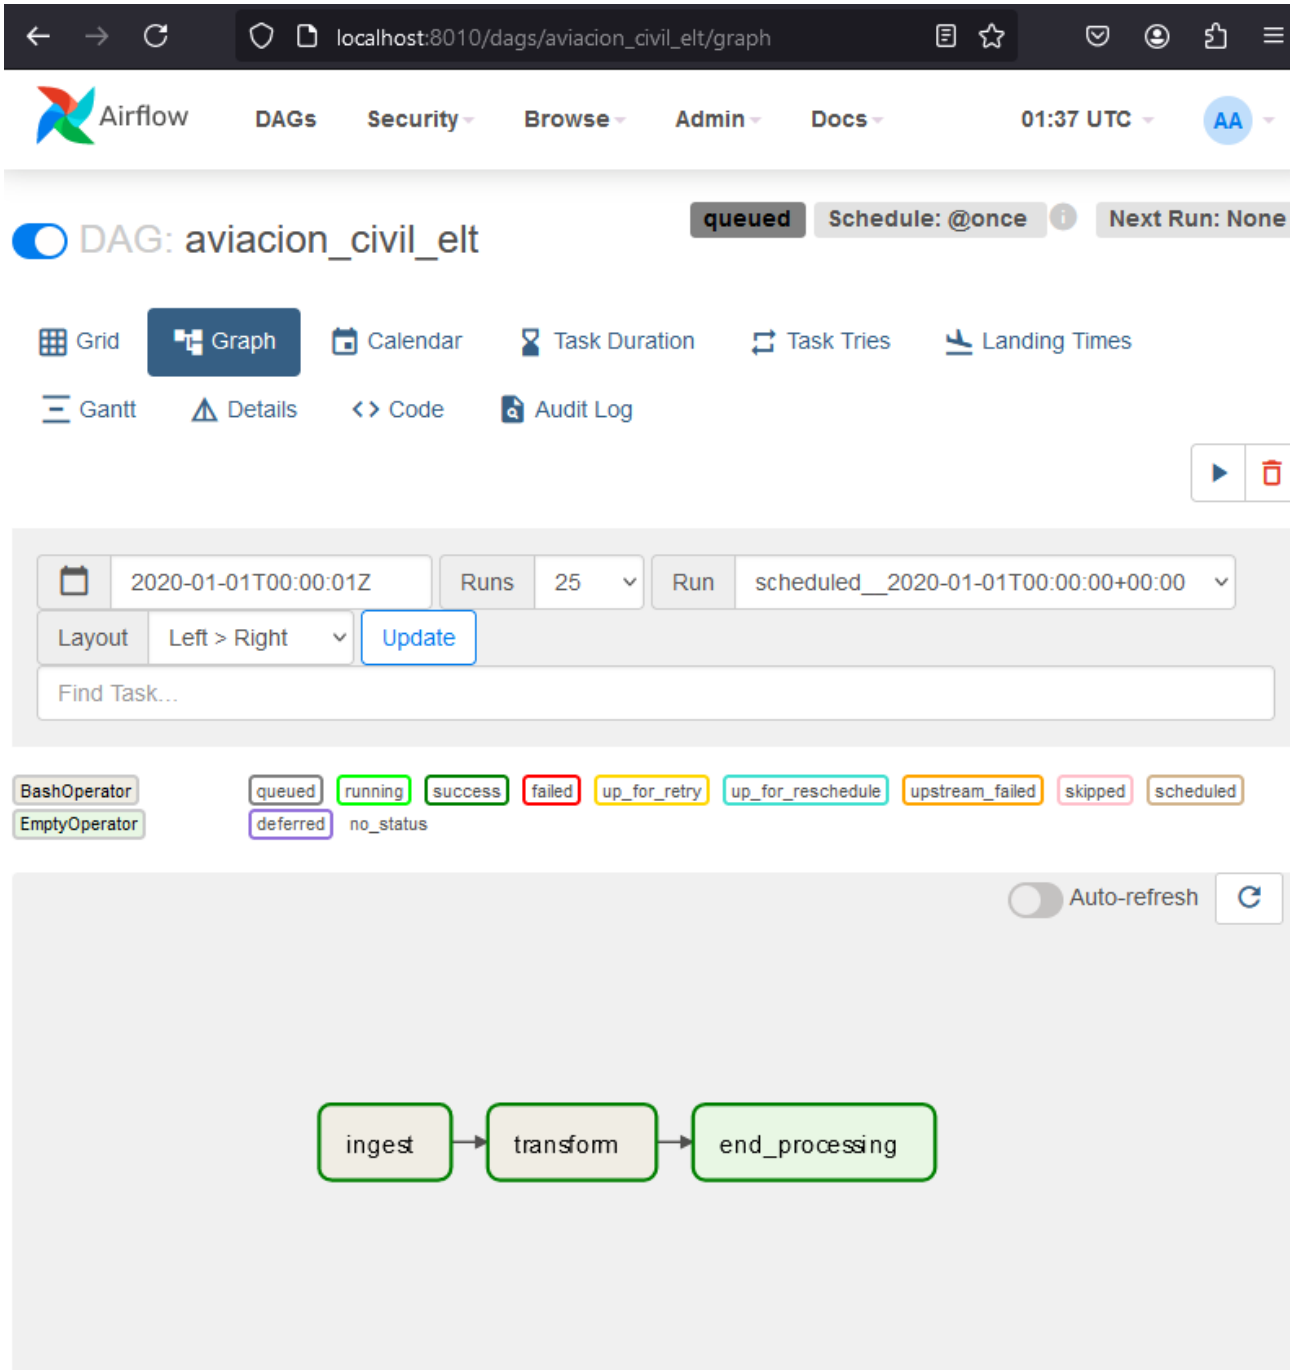

3. Para orquestar el realizar las transformaciones en PySpark se utiliza el siguiente script ubicado en `/home/hadoop/scripts/transform_aviacion.py`

```
from pyspark.context import SparkContext
from pyspark.sql.session import SparkSession
sc = SparkContext('local')
spark = SparkSession(sc)
from pyspark.sql.functions import *
from pyspark.sql import HiveContext
hc = HiveContext(sc)

# Leemos los csv desde HDFS y cargamos en dataframes
df1 = spark.read.option("header", "true").option("sep",";")
      .csv("hdfs://172.17.0.2:9000/ingest/2021-informe-ministerio.csv")
df2 = spark.read.option("header", "true").option("sep",";")
      .csv("hdfs://172.17.0.2:9000/ingest/2022-informe-ministerio.csv")
df_aerop = spark.read.option( "header","true").option( "sep",";")
      .csv("hdfs://172.17.0.2:9000/ingest/aeropuertos_detalle.csv")

# Unimos las tablas de vuelos
df_vuelos = df1.union(df2).distinct()

# Dropeamos columnas que no utilizaremos
df_vuelos = df_vuelos.drop('Calidad dato')
df_aerop = df_aerop.drop("inhab", "fir")

# Normalizamos nombres de columnas
df_vuelos = df_vuelos.withColumnRenamed("Hora UTC","horaUTC")
      .withColumnRenamed("Clase de Vuelo (todos los vuelos)" ,
"clase_de_vuelo")
      .withColumnRenamed("Clasificación Vuelo","clasificacion_de_vuelo")
      .withColumnRenamed("Tipo de Movimiento","tipo_de_movimiento")
      .withColumnRenamed("Aeropuerto","aeropuerto")
      .withColumnRenamed("Origen / Destino","origen_destino")
      .withColumnRenamed("Aerolinea Nombre","aerolinea_nombre")
      .withColumnRenamed("Aeronave","aeronave")
      .withColumnRenamed("Pasajeros","pasajeros")
df_aerop = df_aerop.withColumnRenamed("local","aeropuerto")
      .withColumnRenamed("oaci","oac")

# Casteamos las variables no-string
df_vuelos = df_vuelos
      .withColumn("fecha", to_date("fecha", "dd/MM/yyyy").alias("fecha"))
      .withColumn("pasajeros", col('pasajeros').cast('int'))
df_aerop = df_aerop.withColumn("elev", col('elev').cast('float'))
      .withColumn("distancia_ref", col('distancia_ref').cast('float'))

# Filtramos por fecha
df_vuelos = df_vuelos.filter("fecha ≥ '2021-01-01' AND fecha ≤ '2022-06-
30'")

# Dropeamos los vuelos internacionales
df_vuelos = df_vuelos.filter("clasificacion_de_vuelo ≠ 'Internacional'")
```

```
# Tratamos los nulos
df_vuelos = df_vuelos.withColumn('pasajeros',
      when(col('pasajeros').isNull(), 0 ).otherwise(col('pasajeros')))
df_aerop = df_aerop.withColumn('distancia_ref',
      when(col('distancia_ref').isNull(),0. )
      .otherwise(col('distancia_ref')))

# Creamos vistas con la data filtrada
df_vuelos.createOrReplaceTempView("df_vuelos_vista")
df_aerop.createOrReplaceTempView("df_aerop_vista")

# Insertamos DFs filtrados en tablas de Hive
hc.sql("insert into aviacion_civil.aeropuerto_tabla select * from
df_vuelos_vista;")
hc.sql("insert into aviacion_civil.aeropuerto_detalles_tabla select * from
df_aerop_vista;")
```

4. Chequeamos que el esquema de las tablas sea el correcto, con sus nombres y tipos. Las capturas de pantalla fueron realizadas una vez corrido con éxito el proceso de orquestación en Airflow y los datos procesados por PySpark y ya cargados en Hive.

```
hive> describe formatted aeropuerto_tabla;
OK
# col_name              data_type               comment

fecha                   date
horautc                 string
clase_de_vuelo          string
clasificacion_de_vuelo  string
tipo_de_movimiento      string
aeropuerto              string
origen_destino          string
aerolinea_nombre        string
aeronave                string
pasajeros               int

# Detailed Table Information
Database:               aviacion_civil
Owner:                  hadoop
CreateTime:             Sat Jun 22 04:53:14 ART 2024
LastAccessTime:         UNKNOWN
Retention:              0
Location:               hdfs://172.17.0.2:9000/user/hive/warehouse/aviacion_civil.db/aeropuerto_tabla
Table Type:             MANAGED_TABLE
Table Parameters:
        numFiles                1
        numRows                 0
        rawDataSize             0
        totalSize               42121415
        transient_lastDdlTime   1719115281

# Storage Information
SerDe Library:          org.apache.hadoop.hive.serde2.lazy.LazySimpleSerDe
InputFormat:            org.apache.hadoop.mapred.TextInputFormat
OutputFormat:           org.apache.hadoop.hive.ql.io.HiveIgnoreKeyTextOutputFormat
Compressed:             No
Num Buckets:            -1
Bucket Columns:         []
Sort Columns:           []
Storage Desc Params:
        field.delim             ,
        serialization.format    ,
Time taken: 0.136 seconds, Fetched: 39 row(s)
```

```
hive> describe formatted aeropuerto_detalles_tabla;
OK
# col_name              data_type               comment

aeropuerto              string
oac                     string
iata                    string
tipo                    string
denominacion            string
coordenadas             string
latitud                 string
longitud                string
elev                    float
uom_elev                string
ref                     string
distancia_ref           float
direccion_ref           string
condicion               string
control                 string
region                  string
uso                     string
trafico                 string
sna                     string
concesionado            string
provincia               string

# Detailed Table Information
Database:               aviacion_civil
Owner:                  hadoop
CreateTime:             Sat Jun 22 04:53:15 ART 2024
LastAccessTime:         UNKNOWN
Retention:              0
Location:               hdfs://172.17.0.2:9000/user/hive/warehouse/aviacion_civil.db/aero
Table Type:             MANAGED_TABLE
Table Parameters:
        numFiles                1
        numRows                 0
        rawDataSize             0
        totalSize               129700
        transient_lastDdlTime   1719115283

# Storage Information
SerDe Library:          org.apache.hadoop.hive.serde2.lazy.LazySimpleSerDe
InputFormat:            org.apache.hadoop.mapred.TextInputFormat
OutputFormat:           org.apache.hadoop.hive.ql.io.HiveIgnoreKeyTextOutputFormat
Compressed:             No
Num Buckets:            -1
Bucket Columns:         []
Sort Columns:           []
Storage Desc Params:
        field.delim             ,
```

Para la siguiente sección realizo las consultas a Hive desde Dbeaver por una cuestión de comodidad y practicidad de la herramienta. Para ello conectamos con Hive en el puerto 10000:

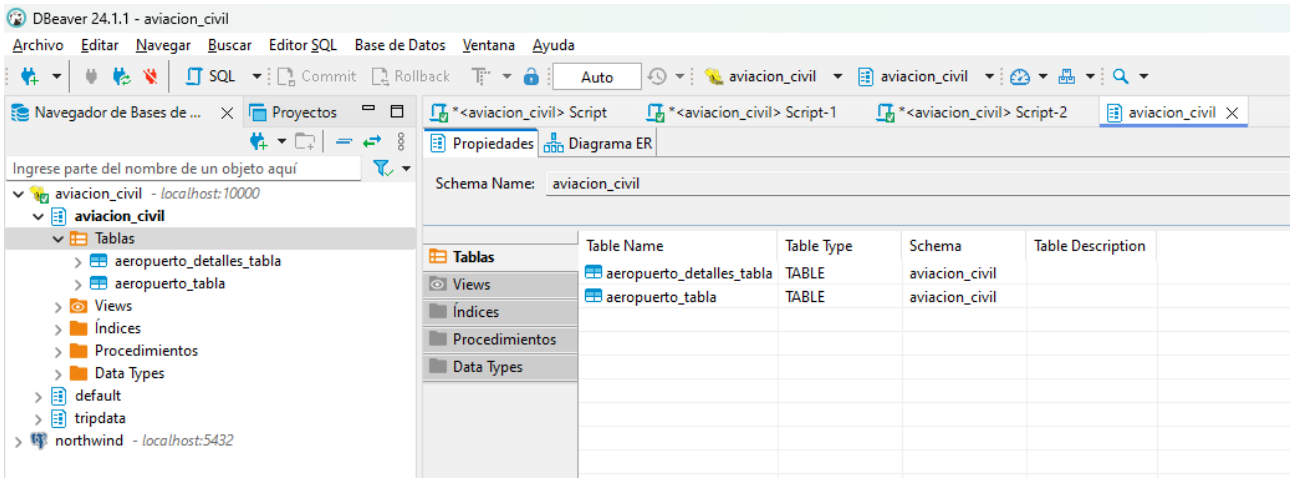

5. Entre las fechas 01/12/2021 y 31/01/2022 se realizaron 57915 vuelos.

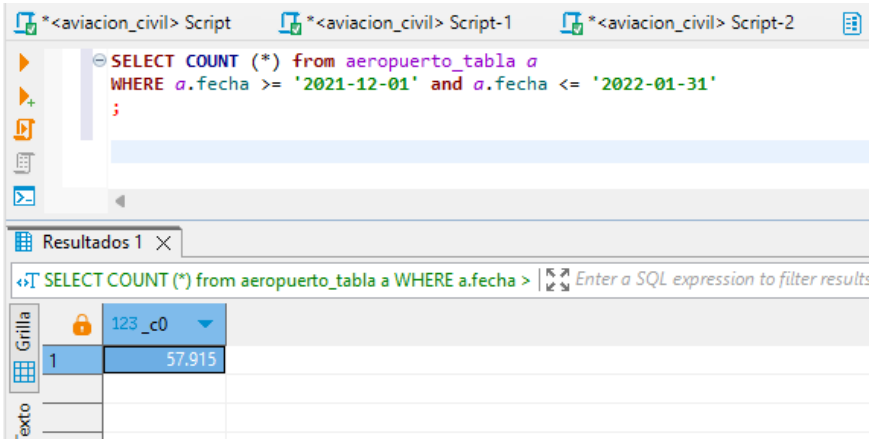

A modo de ejemplo se muestra también la captura de la misma query realizada en la consola de Hive:

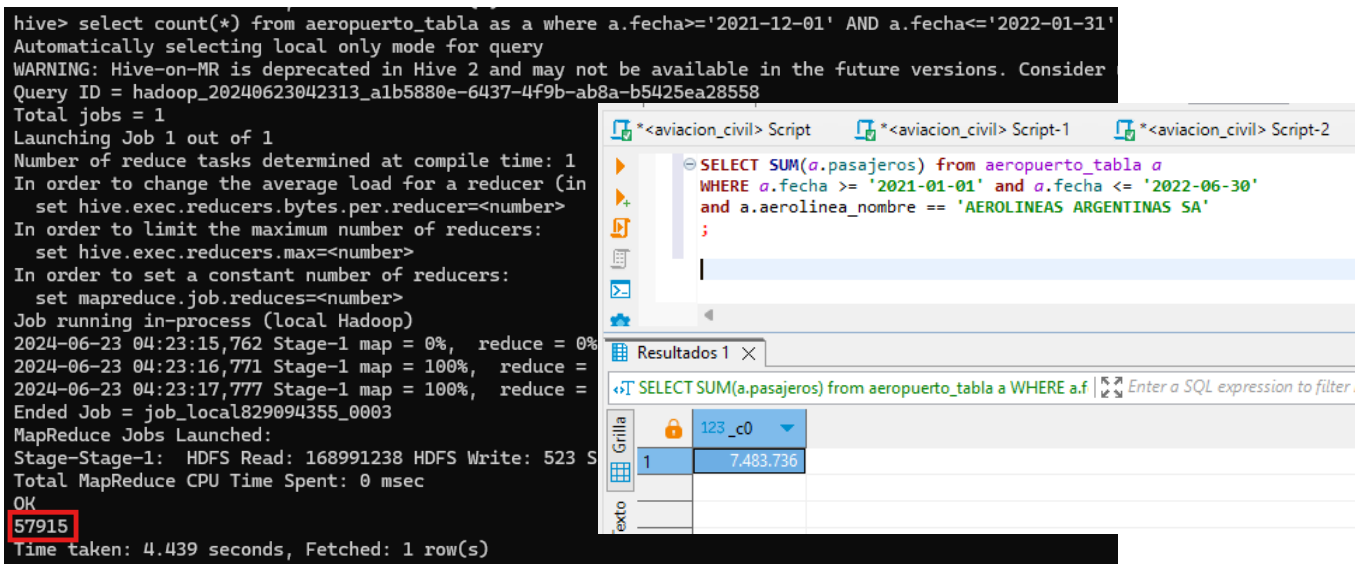

7. Fecha, hora, código aeropuerto salida, ciudad de salida, código de aeropuerto de arribo, ciudad de arribo, y cantidad de pasajeros de cada vuelo, entre el 01/01/2022y el 30/06/2022 ordenados por fecha de manera descendiente.
   Total = 95671 registros.

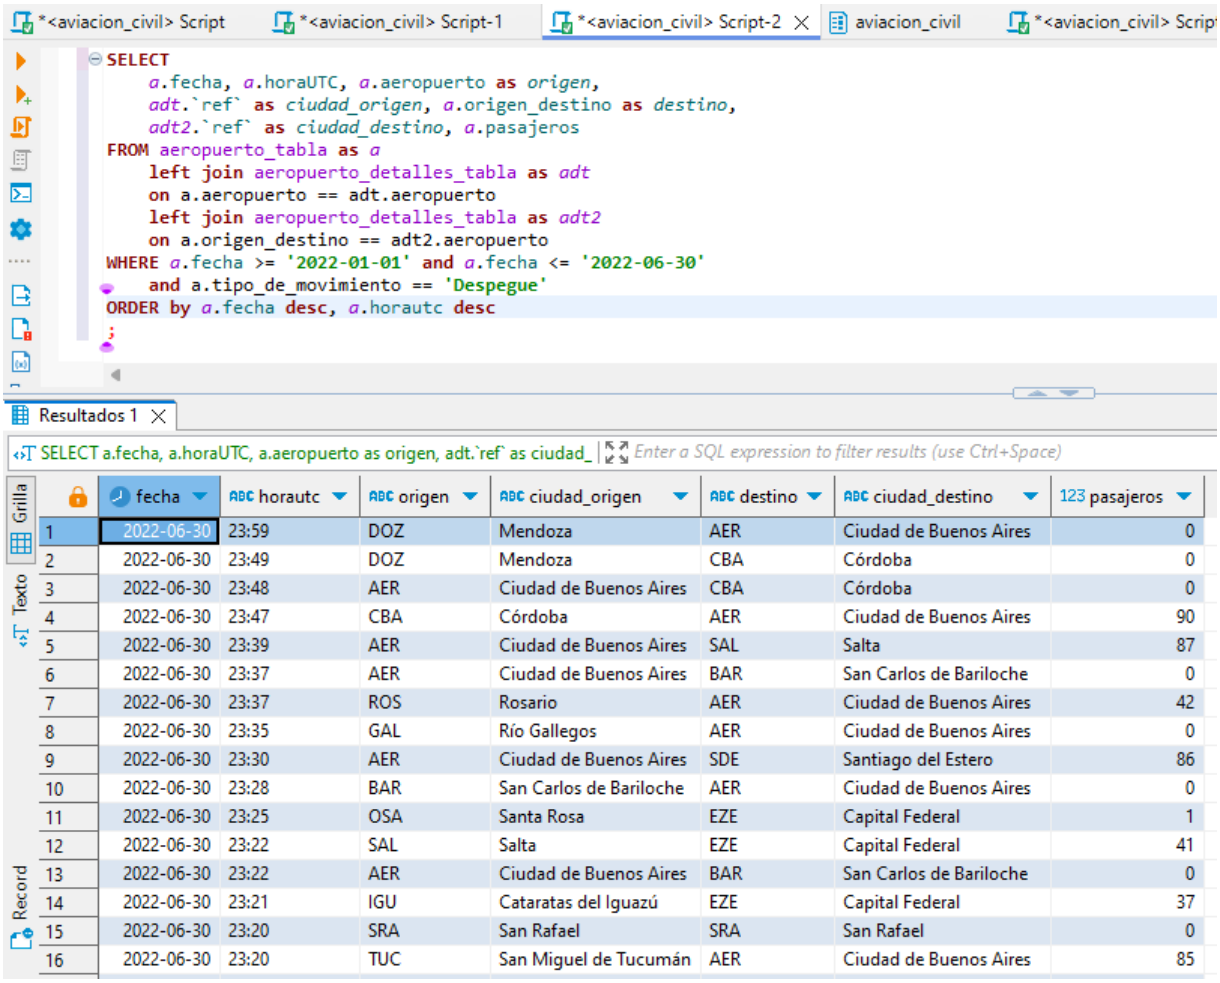

```
SELECT
    a.fecha, a.horaUTC, a.aeropuerto as origen,
    adt.`ref` as ciudad_origen, a.origen_destino as destino,
    adt2.`ref` as ciudad_destino, a.pasajeros
FROM aeropuerto_tabla as a
    left join aeropuerto_detalles_tabla as adt
    on a.aeropuerto == adt.aeropuerto
    left join aeropuerto_detalles_tabla as adt2
    on a.origen_destino == adt2.aeropuerto
WHERE a.fecha >= '2022-01-01' and a.fecha <= '2022-06-30'
    and a.tipo_de_movimiento == 'Despegue'
ORDER by a.fecha desc, a.horautc desc
;
```

Resultados 1

	fecha	horautc	origen	ciudad_origen	destino	ciudad_destino	pasajeros
1	2022-06-30	23:59	DOZ	Mendoza	AER	Ciudad de Buenos Aires	0
2	2022-06-30	23:49	DOZ	Mendoza	CBA	Córdoba	0
3	2022-06-30	23:48	AER	Ciudad de Buenos Aires	CBA	Córdoba	0
4	2022-06-30	23:47	CBA	Córdoba	AER	Ciudad de Buenos Aires	90
5	2022-06-30	23:39	AER	Ciudad de Buenos Aires	SAL	Salta	87
6	2022-06-30	23:37	AER	Ciudad de Buenos Aires	BAR	San Carlos de Bariloche	0
7	2022-06-30	23:37	ROS	Rosario	AER	Ciudad de Buenos Aires	42
8	2022-06-30	23:35	GAL	Río Gallegos	AER	Ciudad de Buenos Aires	0
9	2022-06-30	23:30	AER	Ciudad de Buenos Aires	SDE	Santiago del Estero	86
10	2022-06-30	23:28	BAR	San Carlos de Bariloche	AER	Ciudad de Buenos Aires	0
11	2022-06-30	23:25	OSA	Santa Rosa	EZE	Capital Federal	1
12	2022-06-30	23:22	SAL	Salta	EZE	Capital Federal	41
13	2022-06-30	23:22	AER	Ciudad de Buenos Aires	BAR	San Carlos de Bariloche	0
14	2022-06-30	23:21	IGU	Cataratas del Iguazú	EZE	Capital Federal	37
15	2022-06-30	23:20	SRA	San Rafael	SRA	San Rafael	0
16	2022-06-30	23:20	TUC	San Miguel de Tucumán	AER	Ciudad de Buenos Aires	85

8. Las 10 aerolíneas que más pasajeros llevaron entre el 01/01/2021 y el 30/06/2022 exceptuando aquellas aerolíneas que no tengan nombre.

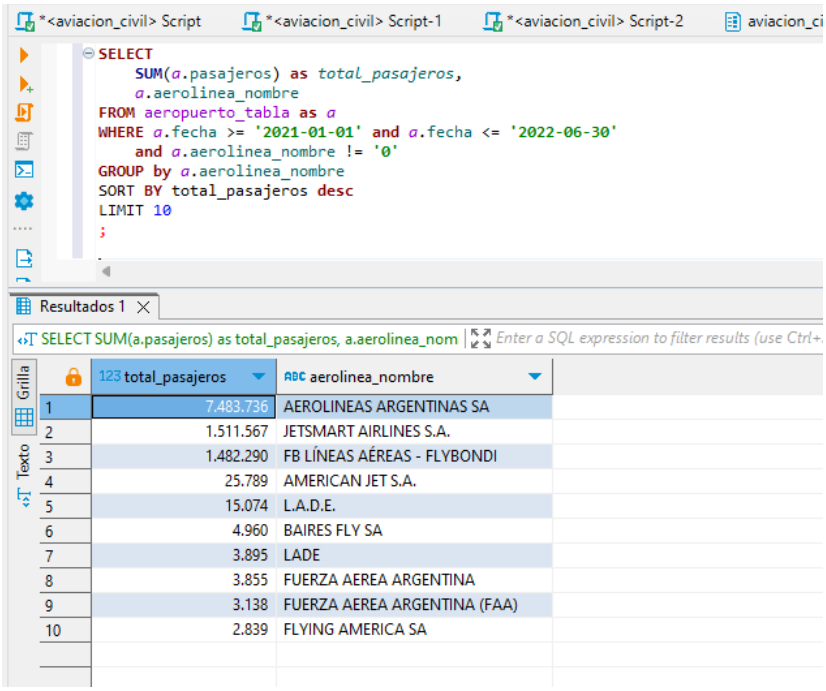

```
SELECT
    SUM(a.pasajeros) as total_pasajeros,
    a.aerolinea_nombre
FROM aeropuerto_tabla as a
WHERE a.fecha >= '2021-01-01' and a.fecha <= '2022-06-30'
    and a.aerolinea_nombre != '0'
GROUP by a.aerolinea_nombre
SORT BY total_pasajeros desc
LIMIT 10
;
```

Resultados 1

	total_pasajeros	aerolinea_nombre
1	7.483.736	AEROLINEAS ARGENTINAS SA
2	1.511.567	JETSMART AIRLINES S.A.
3	1.482.290	FB LÍNEAS AÉREAS - FLYBONDI
4	25.789	AMERICAN JET S.A.
5	15.074	L.A.D.E.
6	4.960	BAIRES FLY SA
7	3.895	LADE
8	3.855	FUERZA AEREA ARGENTINA
9	3.138	FUERZA AEREA ARGENTINA (FAA)
10	2.839	FLYING AMERICA SA

9. Las 10 aeronaves más utilizadas entre el 01/01/2021 y el 30/06/22 que despegaron desde la Ciudad autónoma de Buenos Aires o de Buenos Aires, exceptuando aquellas aeronaves que no cuentan con nombre.

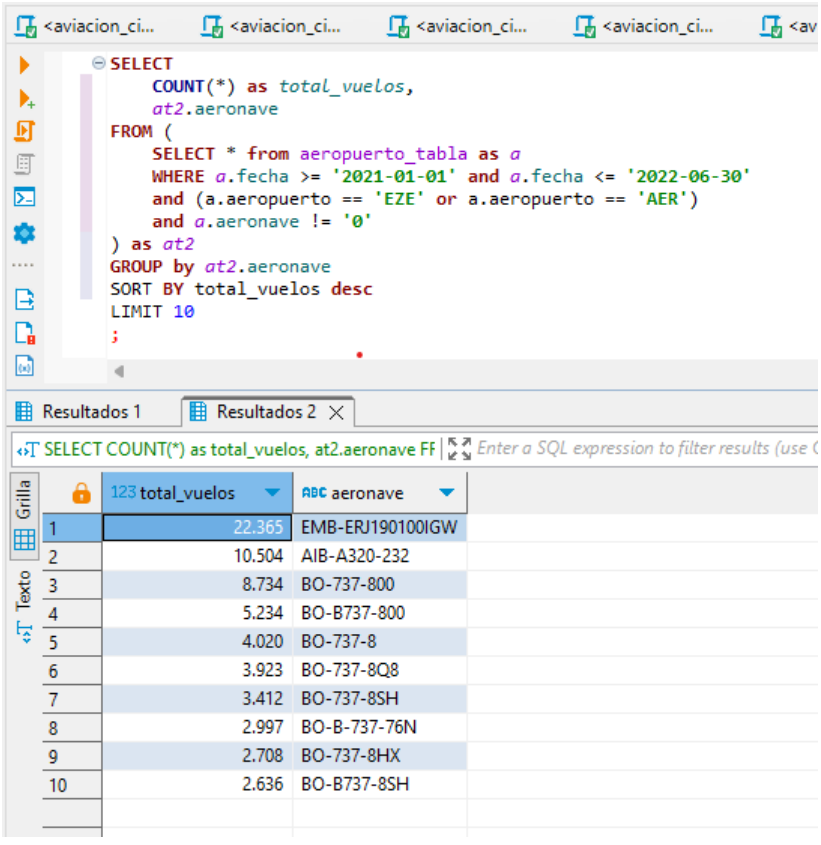

```
SELECT
    COUNT(*) as total_vuelos,
    at2.aeronave
FROM (
    SELECT * from aeropuerto_tabla as a
    WHERE a.fecha >= '2021-01-01' and a.fecha <= '2022-06-30'
    and (a.aeropuerto == 'EZE' or a.aeropuerto == 'AER')
    and a.aeronave != '0'
) as at2
GROUP by at2.aeronave
SORT BY total_vuelos desc
LIMIT 10
;
```

Resultados 1 | Resultados 2

	total_vuelos	aeronave
1	22.365	EMB-ERJ190100IGW
2	10.504	AIB-A320-232
3	8.734	BO-737-800
4	5.234	BO-B737-800
5	4.020	BO-737-8
6	3.923	BO-737-8Q8
7	3.412	BO-737-8SH
8	2.997	BO-B-737-76N
9	2.708	BO-737-8HX
10	2.636	BO-B737-8SH

10. Considero que contar con un identificador único de vuelo facilitaría grandemente las consultas sobre la base y ayudaría a identificar vuelos con información de despegue y aterrizaje no coincidentes.

11. _

12. Una arquitectura equivalente podría implementarse en GCP utilizando:

    - _ para la Ingesta de csv.
    - Google Cloud Storage (GCS Bucket) como datawarehouse.
    - DataProc para las Transformaciones.
    - BigQuery para las consultas.
    - Dataflow para la orquestación del pipeline.