Examen Final

Alumno: Federico Bonino Fecha: 24 de Junio de 2024

Ejercicio 2 – Car Rental

Consigna

Una de las empresas líderes en alquileres de automóviles solicita una serie de dashboards y reportes para poder basar sus decisiones en datos. Entre los indicadores mencionados se encuentran total de alquileres, segmentación por tipo de combustible, lugar, marca y modelo de automóvil, valoración de cada alquiler, etc.

Como Data Engineer debe crear y automatizar el pipeline para tener como resultado los datos listos para ser visualizados y responder las preguntas de negocio.

Desarrollo

 Para crear las tablas en el datawarehouse se utiliza el siguiente script ubicado en /home/hadoop/scripts/create_database_rental.hql
 El script se corrió manualmente por consola antes de realizar la ingesta mediante hive -f /home/hadoop/scripts/create_database_rental.hql

```
-- Create the database
create database car_rental_db;
use car_rental_db;
-- create tables with appropiate schema
create table
    car_rental_analytics (
        fuelType string,
        rating int,
        renterTripsTaken int,
        reviewCount int,
        city string,
        state_name string,
        owner_id int,
        rate_daily int,
        make string,
        model string,
        year int,
        -- Geo_Point string,
        -- Geo_Shape string,
        year_georef string,
        Code_State int,
        Name_State string,
        Area_Code string,
        Type string,
        state_abbreviation string,
        GNIS_Code int
    row format delimited
    fields terminated by ',';
```

Chequeamos que el esquema de las tablas sea el correcto, con sus nombres y tipos.

```
hive> describe formatted car_rental_analytics;
OK
# col_name
                        data_type
                                                 comment
fueltype
                        string
rating
                        int
                        int
rentertripstaken
reviewcount
                        int
                        string
city
state_name
                        string
owner_id
                        int
rate_daily
                        int
make
                        string
model
                        string
year
                        int
                        int
year_georef
code_state
                        int
                        string
name_state
area_code
                        string
                        string
type
state_abbreviation
                        string
gnis_code
                        int
# Detailed Table Information
Database:
                        car_rental_db
Owner:
                        hadoop
CreateTime:
                        Tue Jun 25 02:21:26 ART 2024
                        UNKNOWN
LastAccessTime:
Retention:
                        hdfs://172.17.0.2:9000/user/hive/warehouse/car_rental_db.db/
Location:
Table Type:
                        MANAGED_TABLE
Table Parameters:
        numFiles
                                1
        numRows
                                0
        rawDataSize
                                0
        totalSize
                                483018
        transient_lastDdlTime
                                1719292904
# Storage Information
SerDe Library:
                        org.apache.hadoop.hive.serde2.lazy.LazySimpleSerDe
InputFormat:
                        org.apache.hadoop.mapred.TextInputFormat
OutputFormat:
                        org.apache.hadoop.hive.ql.io.HiveIgnoreKeyTextOutputFormat
Compressed:
                        No
Num Buckets:
                        -1
                        Bucket Columns:
Sort Columns:
Storage Desc Params:
        field.delim
        serialization.format
Time taken: 0.108 seconds, Fetched: 47 row(s)
```

2. Para realizar la ingesta se utiliza el siguiente script ubicado en /home/hadoop/scripts/ingest_rental.sh

```
rm -f /home/hadoop/landing/*.*
wget -0 /home/hadoop/landing/CarRentalData.csv
"https://edvaibucket.blob.core.windows.net/data-engineer-edvai/CarRentalData.csv?sp=r&st=2023-11-06T12:52:39Z&se=2025-11-06T20:52:39Z&sv=2022-11-02&sr=c&sig=J4Ddi2c7Ep230hQLPisbYaerlH472iigPwc1%2FkG80EM%3D"
wget -0 /home/hadoop/landing/georef.csv
"https://dataengineerpublic.blob.core.windows.net/data-engineer/georef-united-states-of-america-state.csv"
/home/hadoop/hadoop/bin/hdfs dfs -rm /ingest/*.*
/home/hadoop/hadoop/bin/hdfs dfs -put /home/hadoop/landing/*.* /ingest
```

3. Para orquestar el realizar las transformaciones en PySpark se utiliza el siguiente script ubicado en /home/hadoop/scripts/transform_rental.py

```
from pyspark.context import SparkContext
from pyspark.sql.session import SparkSession
sc = SparkContext('local')
spark = SparkSession(sc)
from pyspark.sql.functions import *
from pyspark.sql import HiveContext
hc = HiveContext(sc)
### Inicio del Script ###
# Leemos los csv desde HDFS y cargamos en dataframes
df_rental = spark.read.option("header", "true").option("sep",
",").csv("hdfs://172.17.0.2:9000/ingest/CarRentalData.csv")
df_georef = spark.read.option("header", "true").option("sep",
";").csv("hdfs://172.17.0.2:9000/ingest/georef.csv")
# Dropeamos columnas que no utilizaremos
df_rental = df_rental.drop('location.country', 'location.latitude',
'location.longitude', 'vehicle.type')
df_georef = df_georef.drop('State FIPS Code')
# Normalizamos nombres de columnas
# Importante mantener linea vacia debajo de cada bucle for
for column in df_rental.columns:
    df_rental = df_rental.withColumnRenamed(column,
column.replace('.','_'))
```

```
df_rental =
df_rental.withColumnRenamed("location_city", "city").withColumnRenamed("loc
ation_state", "state_name")
for column in df_rental.columns[-3:]:
    df_rental = df_rental.withColumnRenamed(column, column.split('_')[-1])
for column in df_georef.columns:
    df_georef = df_georef.withColumnRenamed(column,
column.replace('.','_').replace(' ','_'))
for column in df_georef.columns:
    df_georef =
df_georef.withColumnRenamed(column,'_'.join(column.split('_')[-2:]))
df_georef = df_georef.withColumnRenamed("Year", "year_georef")
# Redondeamos los float de 'rating' y castear a int
# Vuelvo a cargar sql.functinos porque levanta error
from pyspark.sql.functions import *
df_rental = df_rental.filter(column("rating").isNotNull())
# Eliminamos 'Texas'
df_rental = df_rental.filter("state_name # 'TX'")
# Joineamos las tablas en 'state_name'
df_rental = df_rental.join( df_georef,
df_rental.state_name==df_georef.state_abbreviation, 'left')
# Casteamos las variables no-string
cast_cols = ['renterTripsTaken', 'reviewCount', 'owner_id', 'rate_daily',
'year', 'year_georef', 'Code_State', 'GNIS_Code']
for column in cast_cols:
    df_rental = df_rental.withColumn( column, col(column).cast('int'))
# Redondeamos los float de 'rating' y castear a int
df_rental = df_rental.withColumn( 'rating',
round('rating').cast('integer') )
# Mayusculas por minusculas en 'fuelType'
df_rental = df_rental.withColumn('fuelType', lower('fuelType') )
# Dropeo columna 'Geo_Point' y 'Geo_Shape'
# --AVERIGUAR COMO TRATAR CON LISTAS GEO-SHAPE
# EL OBJETO DE LISTAS SE CARGA INCORRECCTAMENTE EN HIVE--
df_rental = df_rental.drop('Geo_Point', 'Geo_Shape')
# Creamos vistas con la data filtrada
df_rental.createOrReplaceTempView("df_rental_vista")
# Insertamos DFs filtrados en tablas de Hive
hc.sql("insert into car_rental_db.car_rental_analytics select * from
df_rental_vista;")
### Fin del Script ###
```

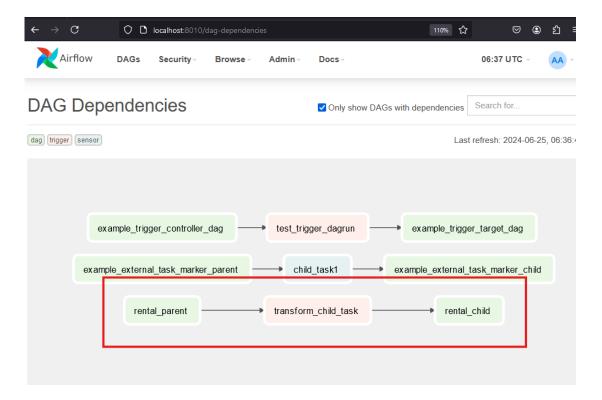
4. Para orquestar el proceso de ETL mediante Airflow se utilizaron dos scripts de manera que un proceso padre realice la ingesta y llame al proceso hijo para realizar las transformaciones. Los scripts que implementan los DAGs son:

/home/hadoop/airflow/dags/dag_rental_parent_TriggerDagRun.py
/home/hadoop/airflow/dags/dag_rental_child_TriggerDagRun.py

```
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.empty import EmptyOperator
from datetime import datetime, timedelta
from airflow.operators.trigger_dagrun import TriggerDagRunOperator
args = {
   'owner' : 'airflow',
with DAG(
    dag_id="rental_parent",
    default_args=args,
    schedule_interval='@once',
    start_date=datetime(2020, 1, 1),
    dagrun_timeout=timedelta(minutes=60),
    tags=['ingest','parent'],
) as parent_dag:
    begin = EmptyOperator(
       task_id='begin_processing',
    ingest = BashOperator(
        task_id='ingest_rental',
        # Don't drop the space at the end of the command or Jinja
will fail
        bash_command='/usr/bin/sh
/home/hadoop/scripts/ingest_rental.sh ',
    transform_child_task = TriggerDagRunOperator(
        task_id="transform_child_task",
        trigger_dag_id='rental_child',
        wait_for_completion=False,
        reset_dag_run=True,
    )
    end = EmptyOperator(
       task_id='end_processing',
    begin >> ingest >> transform_child_task >> end
```

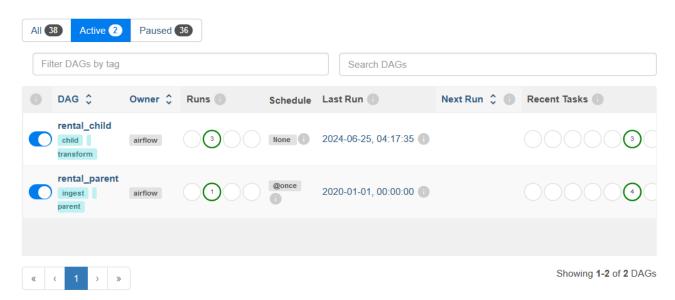
```
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.operators.empty import EmptyOperator
from datetime import datetime, timedelta
args = {
    'owner' : 'airflow',
with DAG(
    dag_id="rental_child",
    default_args=args,
    schedule_interval=None,
    start_date=datetime(2020, 1, 1),
    dagrun_timeout=timedelta(minutes=60),
    tags=['transform','child'],
) as child_dag:
    begin = EmptyOperator(
        task_id='begin_processing',
    transform_rental = BashOperator(
        task_id='transform_rental',
        # Don't drop the space at the end of the command or Jinja
will fail
        bash_command='ssh hadoop@172.17.0.2
/home/hadoop/spark/bin/spark-submit --files
/home/hadoop/hive/conf/hive-site.xml
/home/hadoop/scripts/transform_rental.py ',
    end = EmptyOperator(
        task_id='end_processing',
    begin >> transform_rental >> end
```

En la siguiente captura de pantalla se observa la dependencia entre DAGs generada por Airflow:



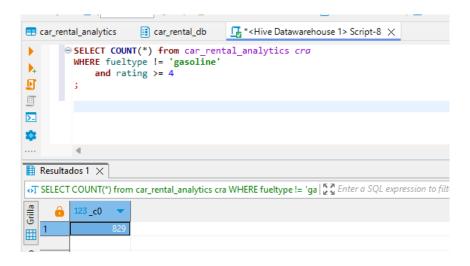
Esta captura de pantalla muestra los DAGs orquestados por Airflow:

DAGs

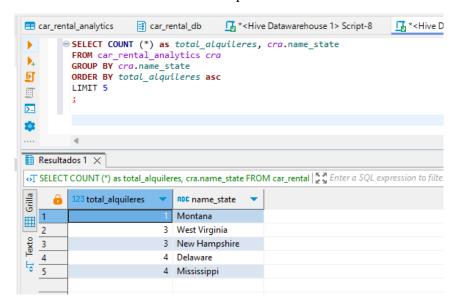


5. Querys

a. 829 autos alquilados ecológicos con rating de al menos 4.



b. Los 5 estados con menor cantidad de alquileres



	d.
6.	_
7.	Una arquitectura equivalente podría implementarse en GCP utilizando:
	• _ para la Ingesta de csv.
	Google Cloud Storage (GCS Bucket) como datawarehouse.
	DataProc para las Transformaciones.

BigQuery para las consultas.

Looker para las visualizaciones.

Dataflow para la orquestación del pipeline.

c. Los 10 modelos (junto con su marca) de autos más rentados